

深層学習を用いた超新星爆発による シェル膨張の予測

東京大学M2 平島敬也



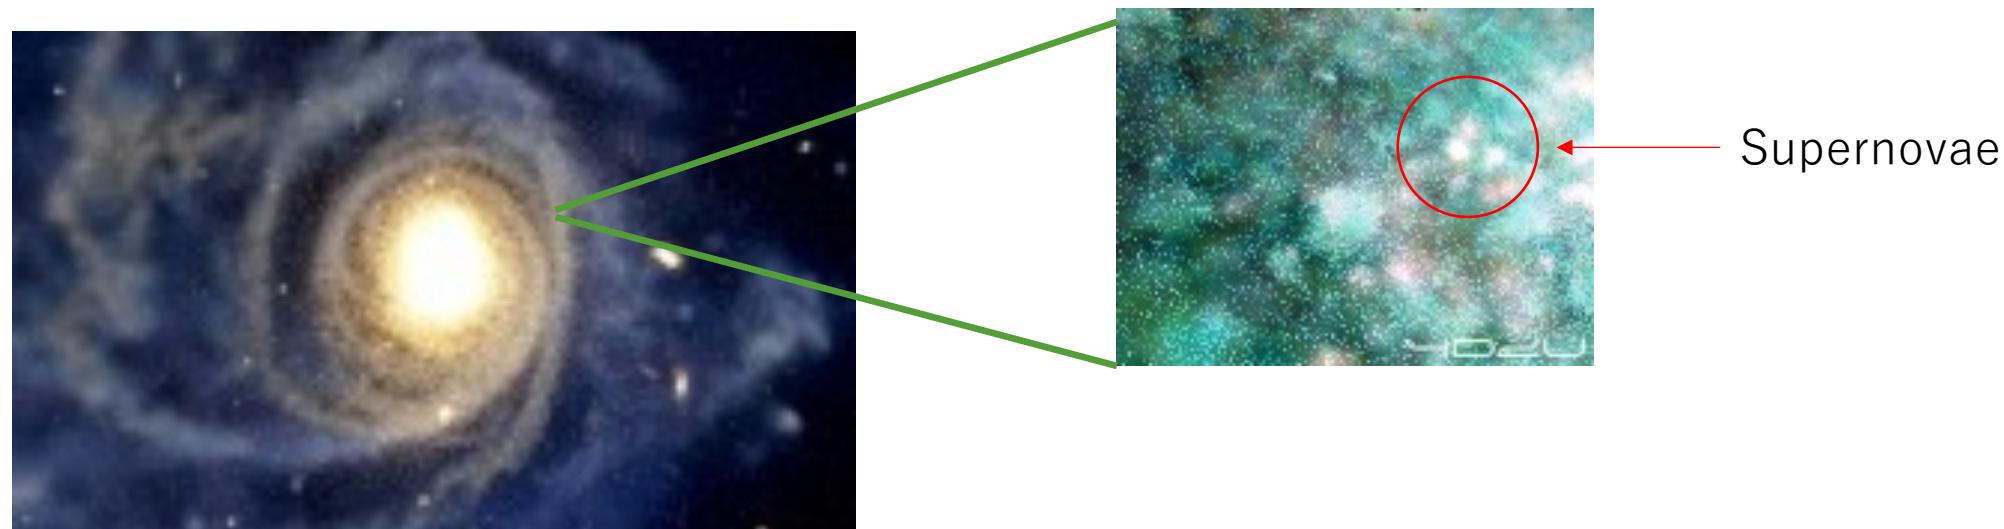
森脇可奈, 藤井通子 (東京大学), 斎藤貴之, 牧野淳一郎 (神戸大学)

Contents

- 1. Introduction – 銀河形成シミュレーションの課題 -
- 2. 深層学習を用いた物理量の時間・空間的変化の予測
- 3. Summary

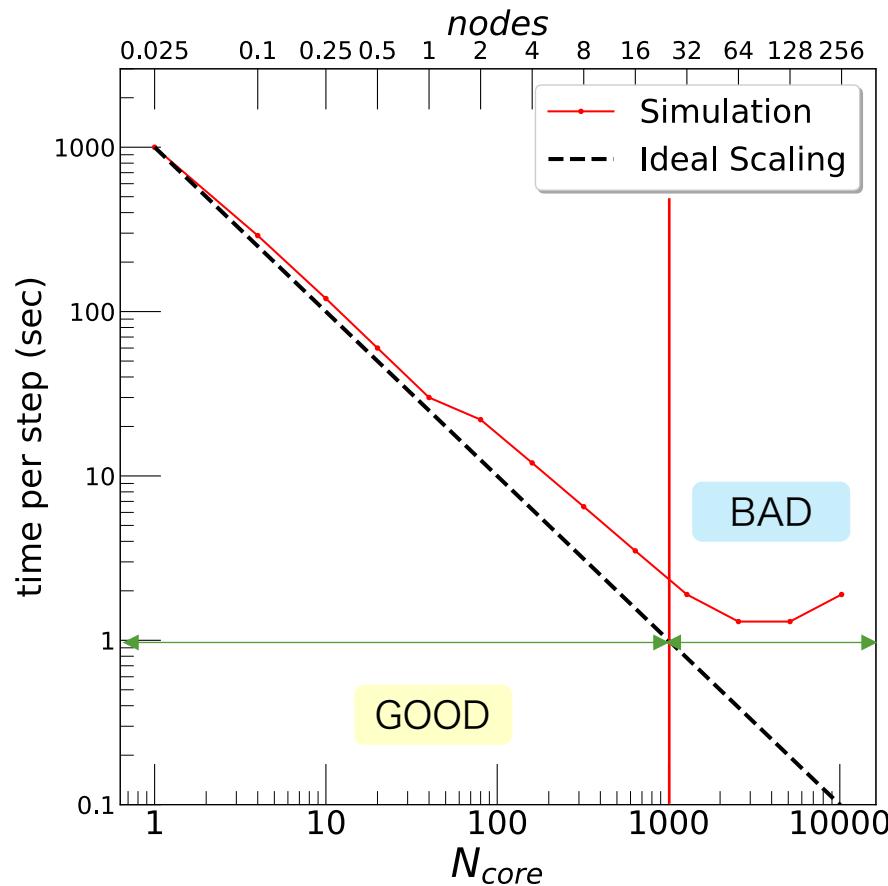
銀河形成シミュレーションのボトルネック

- ・スーパーコンピュータの発展により、個々の星まで分解した銀河形成シミュレーションの達成が目前に迫っている。
 - ・SPHでは $10^3 M_{\odot}$ が達成されているが、ASURA-FDPSでは $1M_{\odot}$ を目指す。
- ・高密度高温領域は安定性の条件が最も厳しい（超新星領域）。
 - ・非常に短い時間刻みが必要になり、並列計算のボトルネックとなる。



高解像度銀河形成シミュレーションのスナップショット
<https://4d2u.nao.ac.jp/t/var/download/movie.html>

大規模並列化の現状



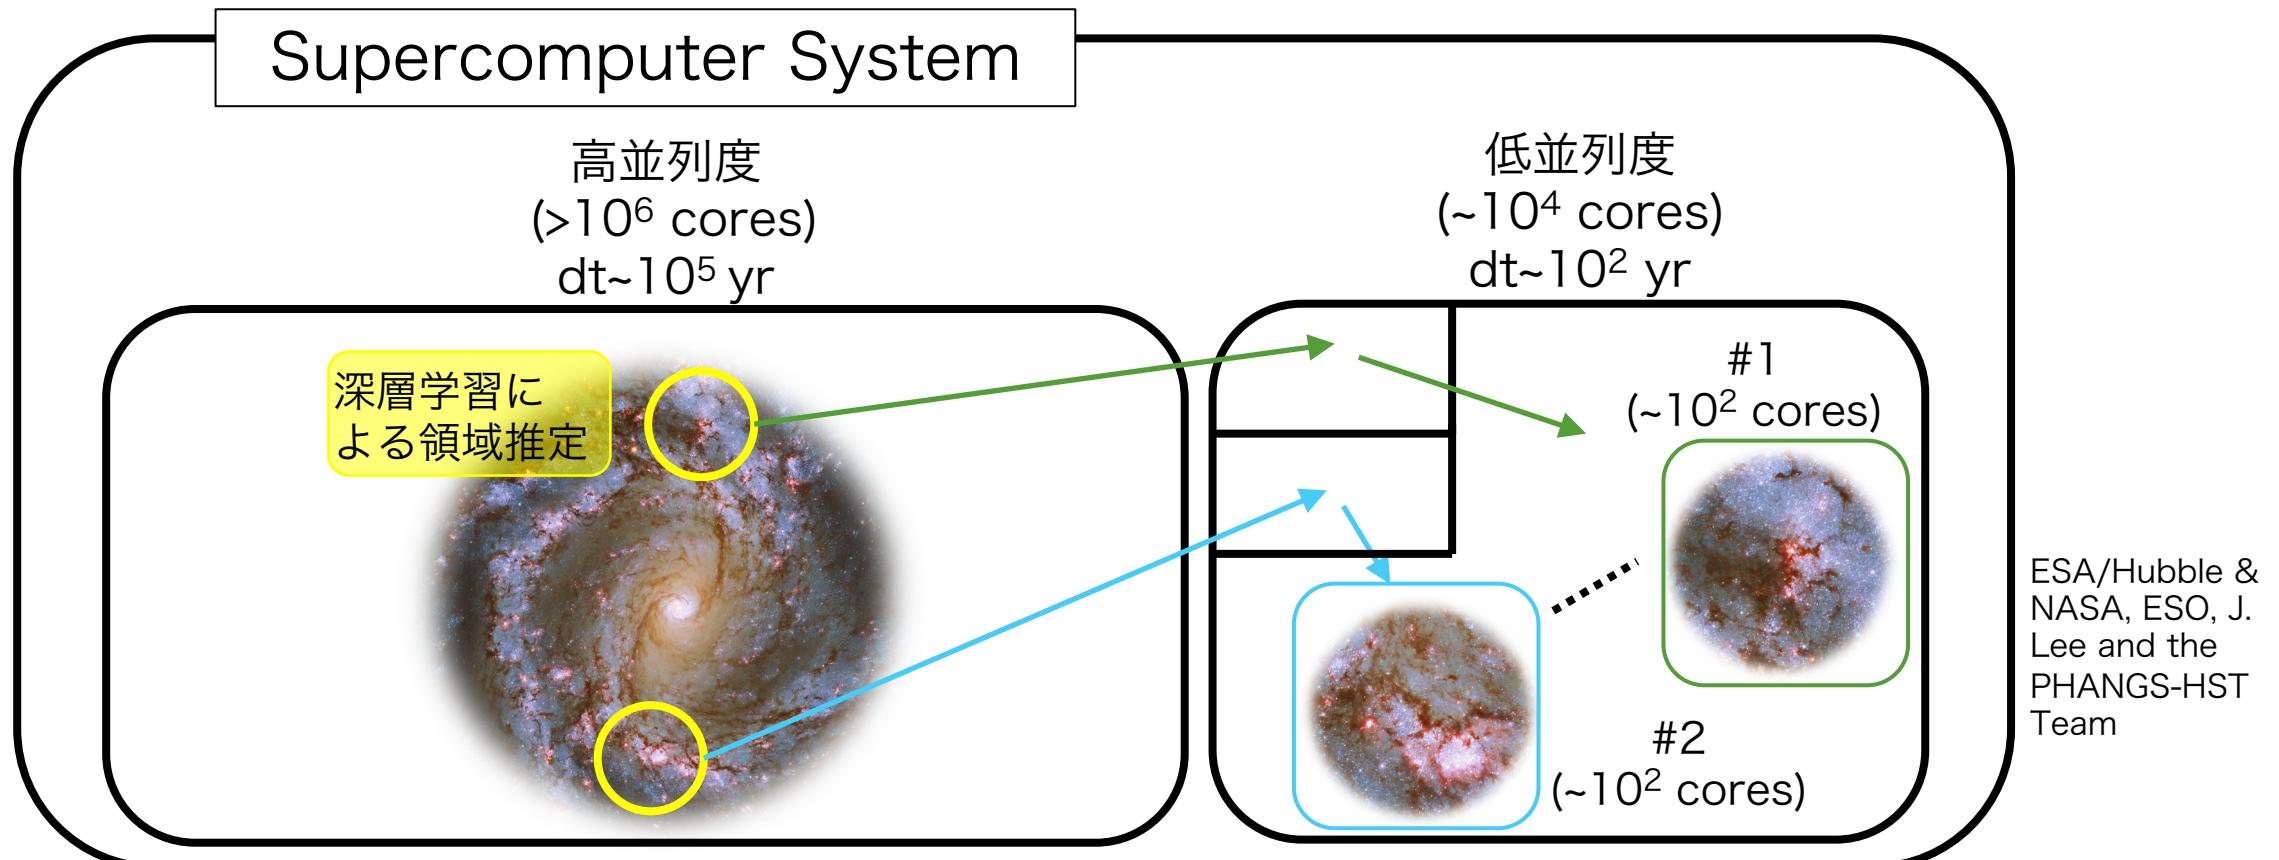
GADGET-4のStrong Scaling
(Springel et al. (2013), Figure 63
より一部改変)

- Communication overhead: 各計算ステップごとの計算ノード間のデータ転送のために生じる遅延。
- 大規模な計算機において並列化効率を悪化させる原因となる。
- 超新星爆発領域は、特にcommunication overheadが大きい。

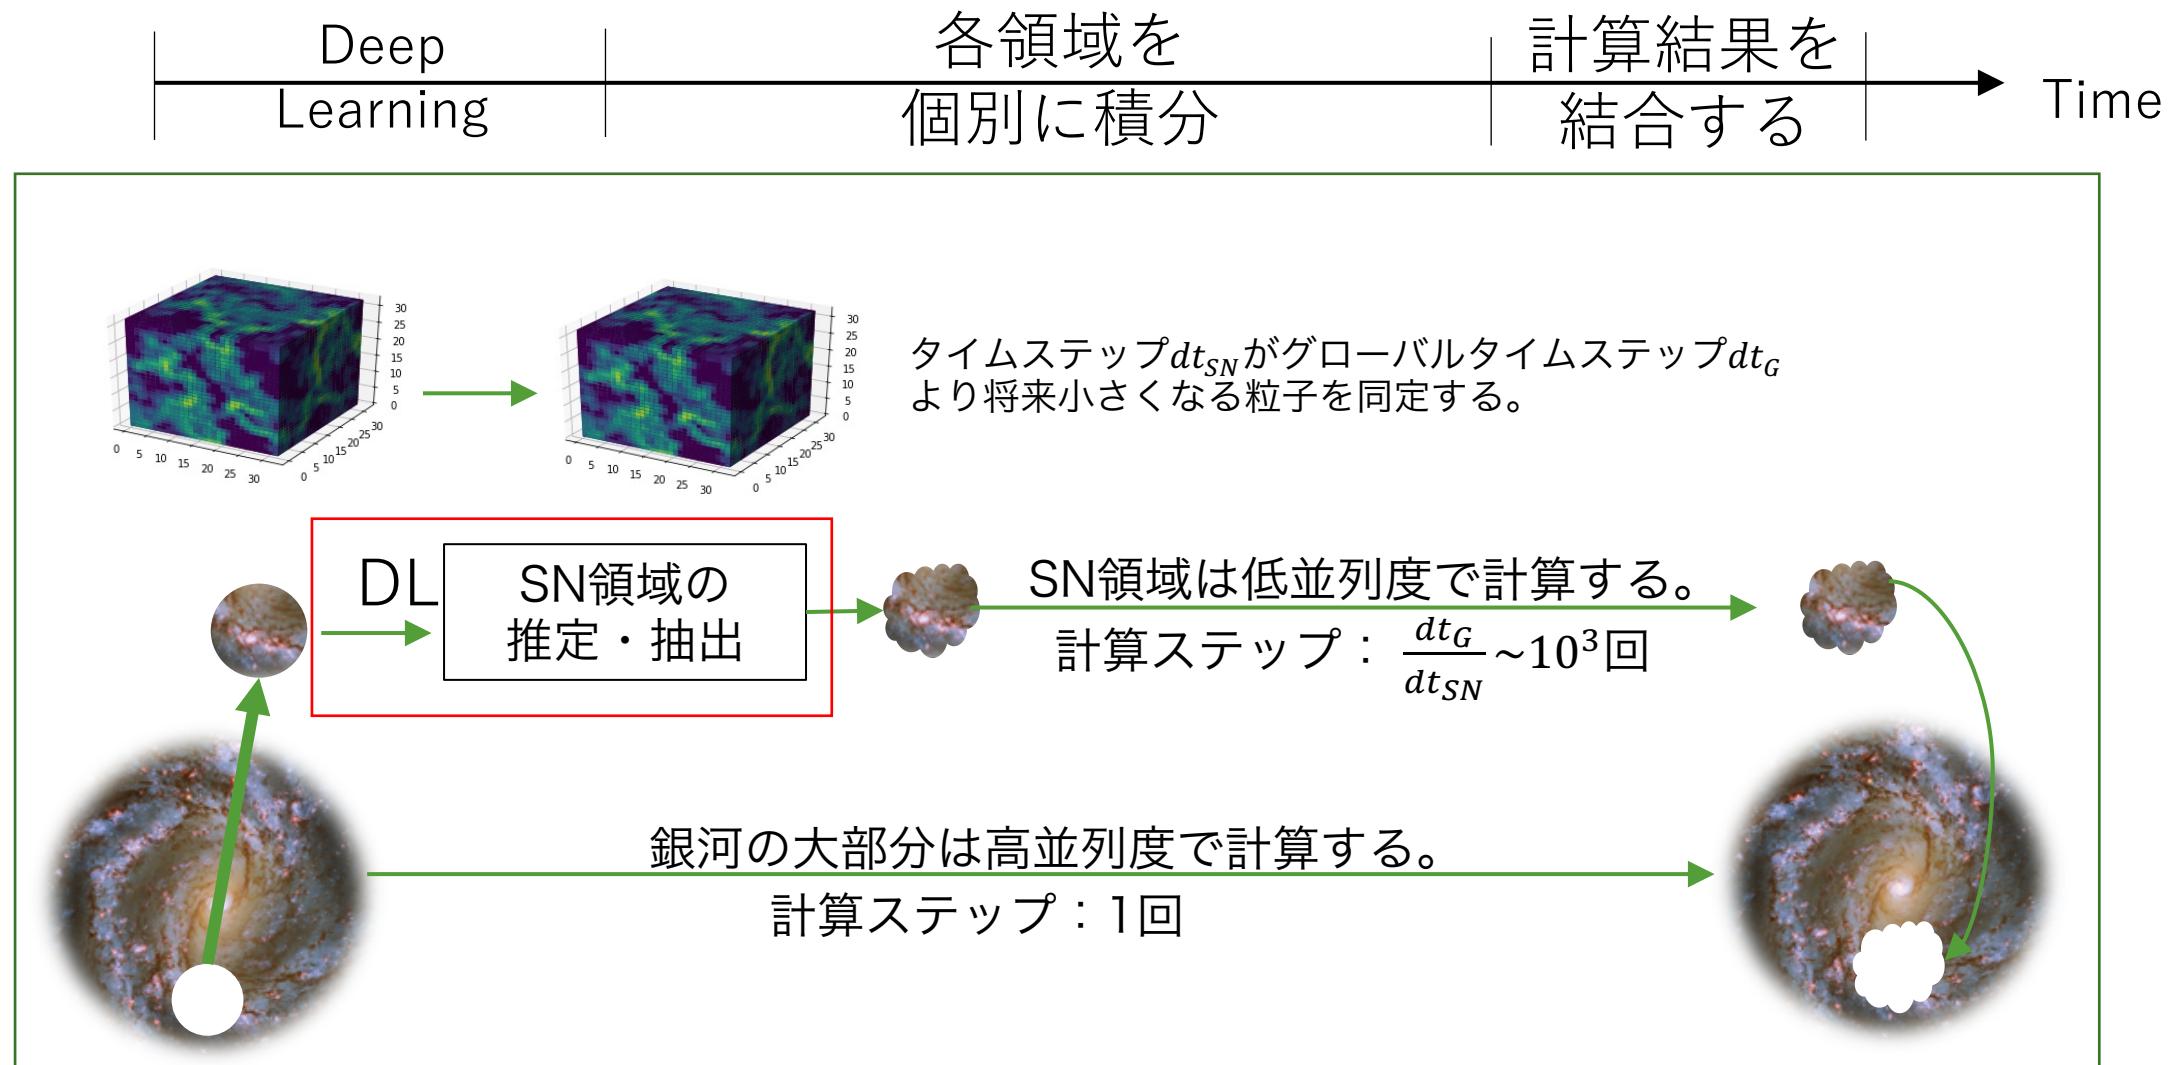
本研究の目的

超新星爆発の影響領域を深層学習により推定・抽出し、その部分を全体とは別に計算することで高速化し、全体の並列化効率を向上させる。

ASURA-FDPSによる銀河形成シミュレーション

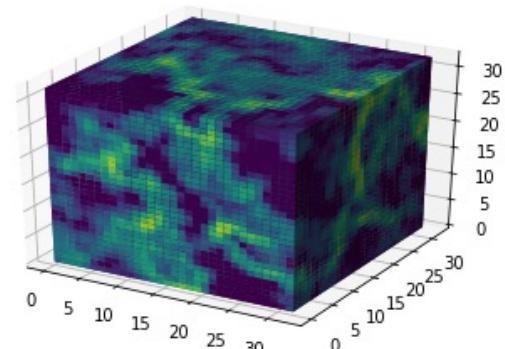


アルゴリズムの全体像

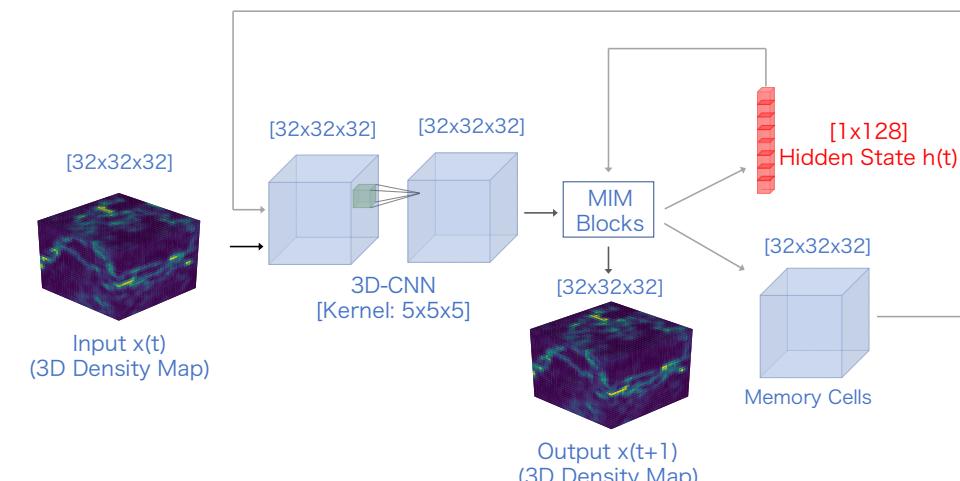


深層学習モデル

- Memory-In-Memory Network (Yunbo Wang et al. (2018))
 - MIM Networkは、映像の時間・空間的な変化を学習し、過去の映像から未来の映像を生成する。
 - 2次元映像(通常の映像)しか学習できない。
- 本研究で開発 3D-MIM
 - データ形式とネットワーク内のテンソルの次元を増やした。
 - 物理量の時間・空間分布の変化を学習・予測可能になった。



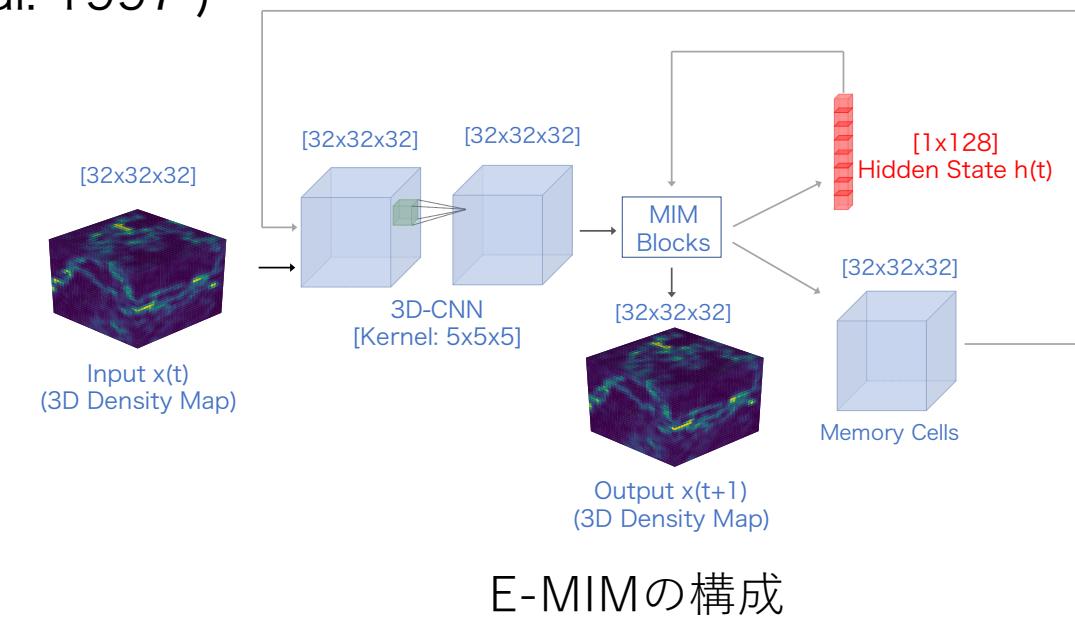
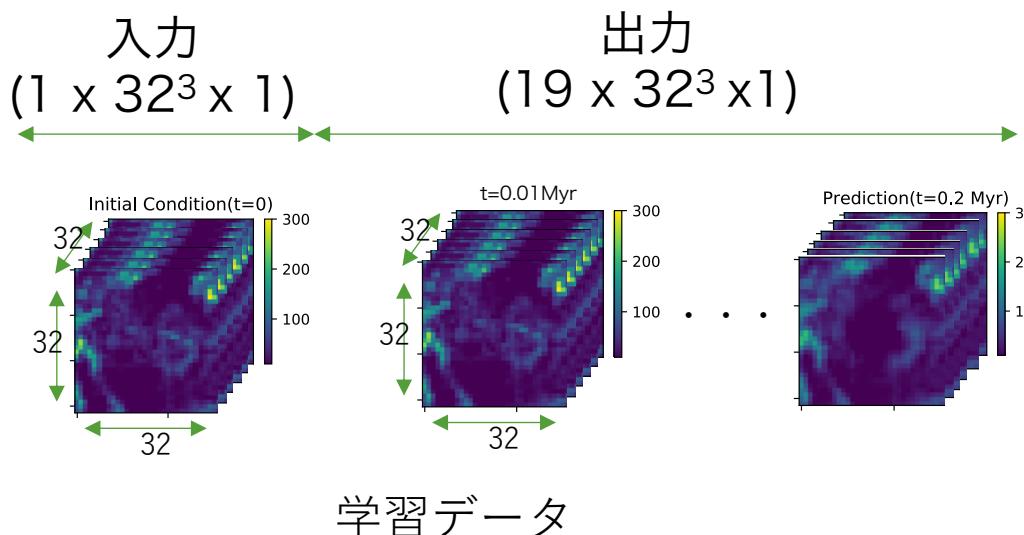
密度分布を表す3次元データ形式



学習方法

- ・シミュレーションの時系列データを学習する。
- ・空間的特徴の抽出：CNN¹ は畳み込み（内積計算）により画像の特徴を抽出する。
- ・時間的変化の抽出：LSTM² は隠れ状態を伝播させることでモデルを更新し、時系列データを学習する。

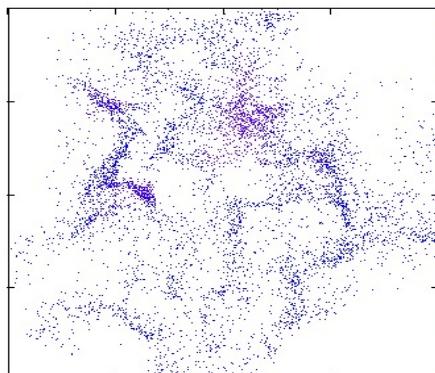
- 1) Convolutional Neural Network (Krizhevsky et al. 2012)
- 2) Long-Short Term Memory (Hochreiter et al. 1997)



学習データ (SPHシミュレーション)

Initial condition of SPH simulations.

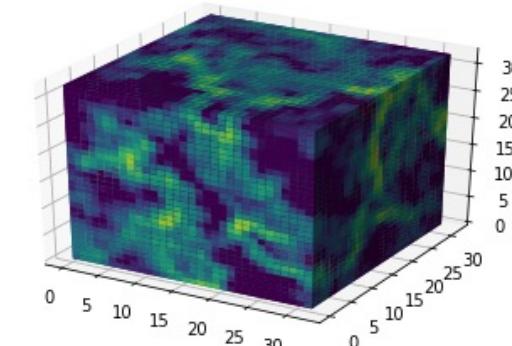
| | |
|------------------------|----------------------|
| Temperature | 100 [K] |
| Input Energy | 10^{51} [erg] |
| Total mass | 10^6 [M_\odot] |
| Mass of a gas particle | 10 [M_\odot] |
| Time for SN | 1.2 [Myr] |
| Length of SN expansion | 0.2 [Myr] |
| Softening Parameter | 3 [pc] |



3次元voxel (mesh)

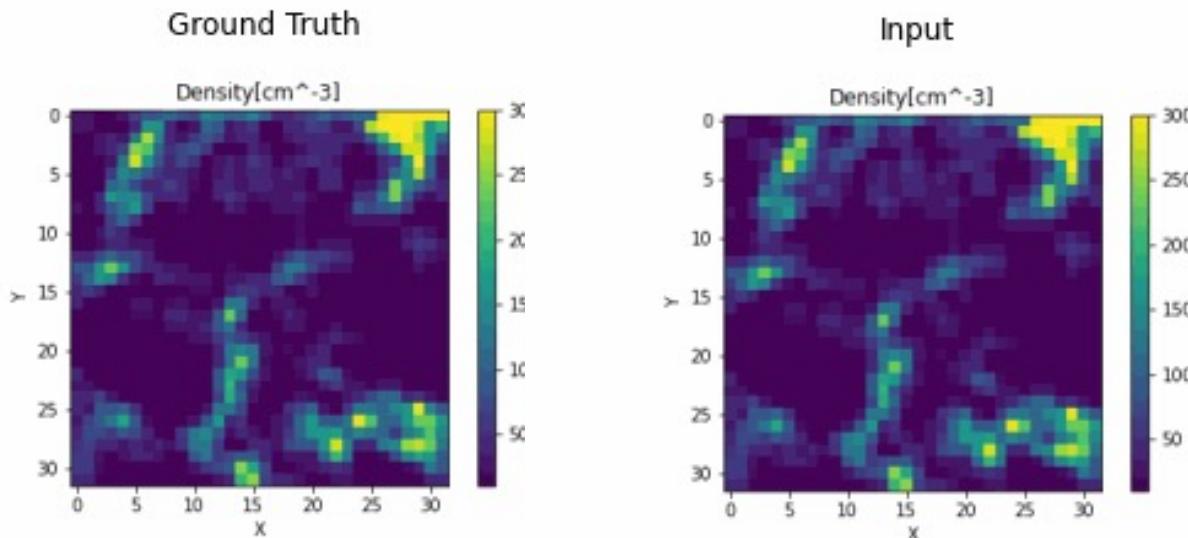


データに変換



SNによるシェル膨張の予測

- 3D-MIMを用いて、初期密度分布からSNによるシェル膨張の変化を予測した。
- 推論自体は1秒以内で終了する。



シミュレーションデータ（正解）
とE-MIMによる予測結果の断面図

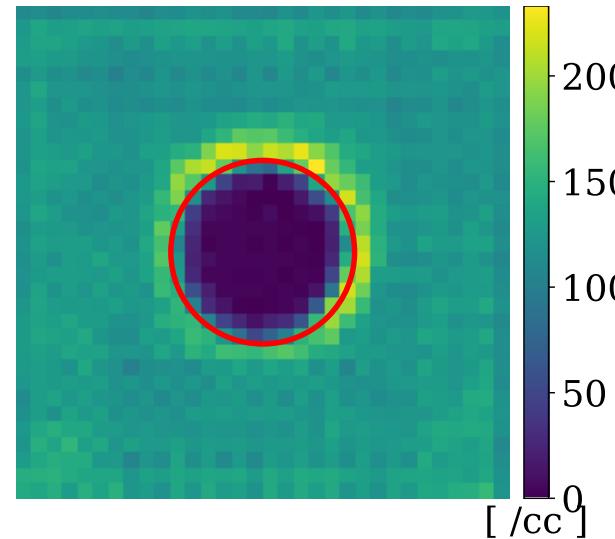
- SPHシミュレーションのデータ
- 3次元密度分布
- Input: 1枚、爆発直前の密度分布
- Output: 19枚、爆発後の密度の時間・空間的変化
- 学習データ：14400個
- データ拡張：独立したシミュレーション結果300個 × 48回転
- 密度以外の物理量(圧力・温度など)も学習可能。

解析解の再現

The Sedov-Taylor Solution
 $R(t) = \xi \left(\frac{E}{\rho} \right)^{1/5} t^{2/5}$

Conditions
• $t = 0.1$ Myr
• $E = 10^{51}$ erg

シミュレーションの
平均密度の一様分布

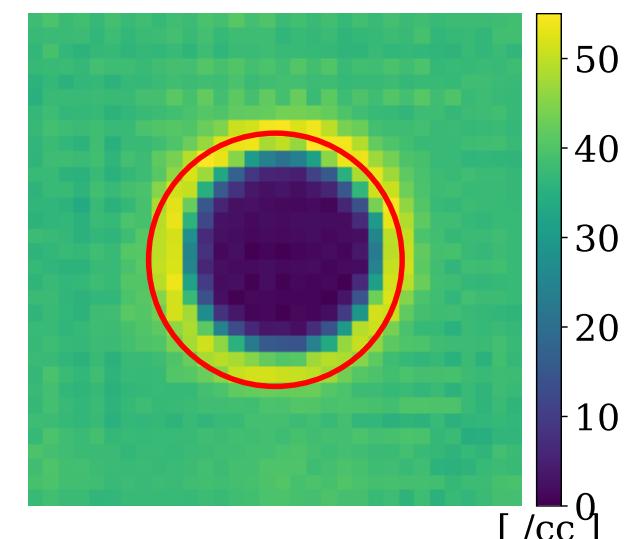


$$R(t) = 11.2 \text{ pc}$$

$$12.53 \div \frac{60}{32} = 5.97 \text{ pixel}$$

シェル半径が解析解と一致する。

シミュレーションの
平均密度の1/5の一様分布



$$R(t) = 15.4 \text{ pc}$$

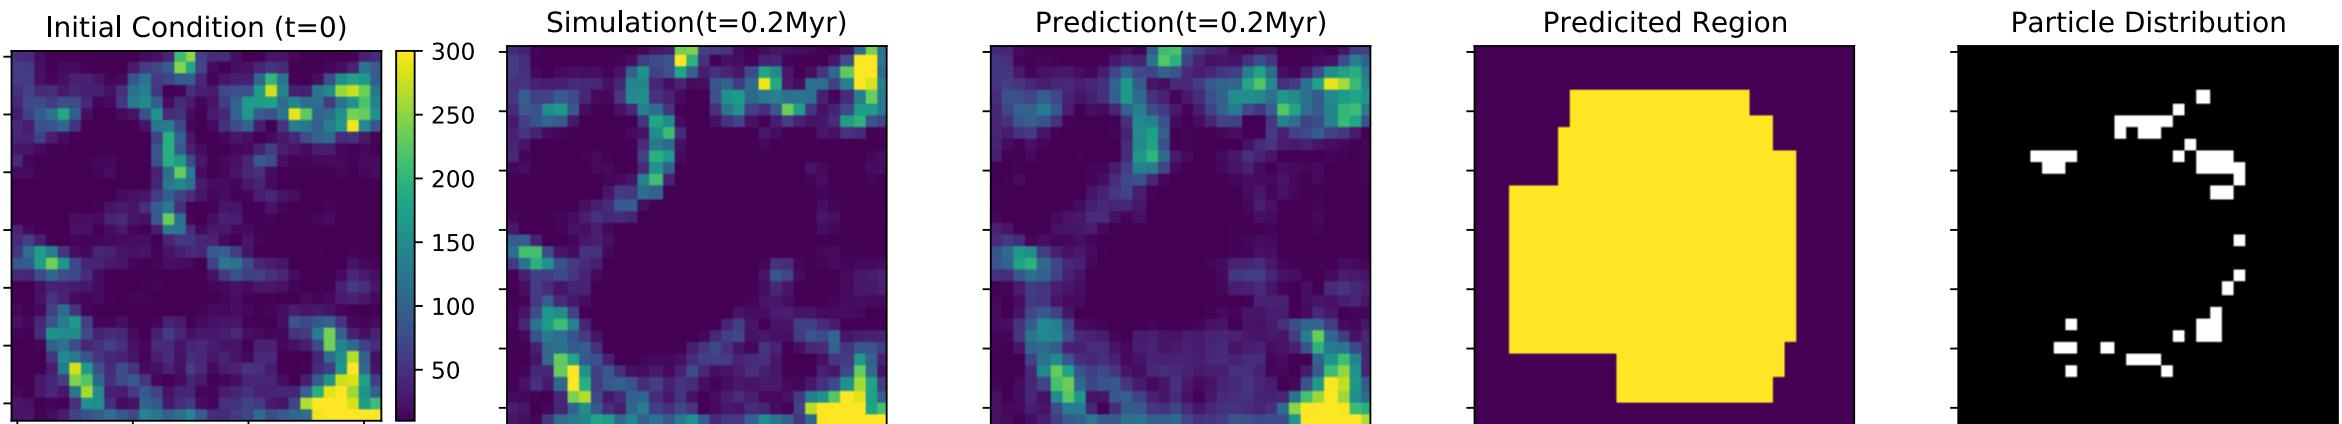
$$17.29 \div \frac{60}{32} = 8.23 \text{ pixel}$$

シェル半径が解析解より小さい。

- 密度依存性が厳密には再現できていないが、大きな問題にはならない。
- 本研究の目的は、粒子が閾値以上に減った領域を推定することだから。

画像処理による領域推定

- ・タイムステップが短い粒子は、超新星爆発によるシェルの境界上に存在する。
- ・密度の予測結果に画像処理を適用し、ある閾値より大きく密度が減少した閉空間を目的の領域として選んだ。

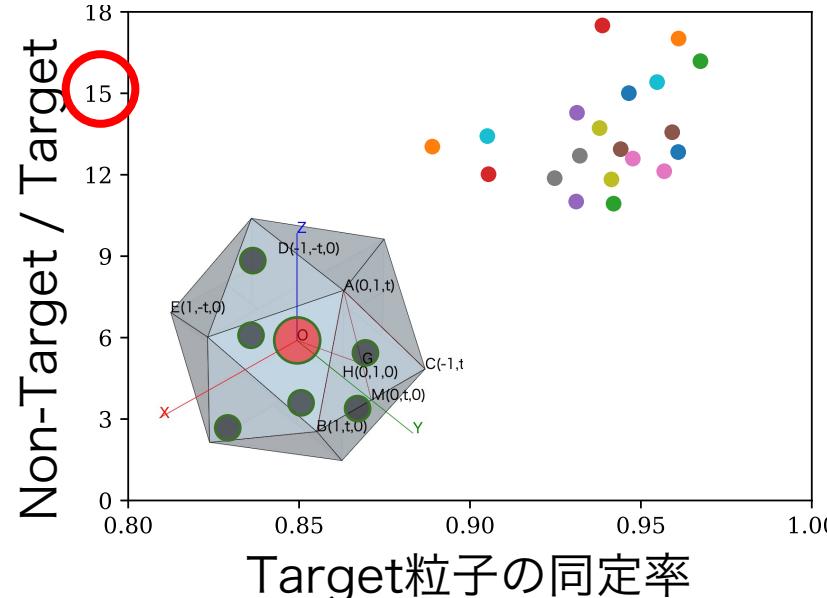


アルゴリズムのパフォーマンス

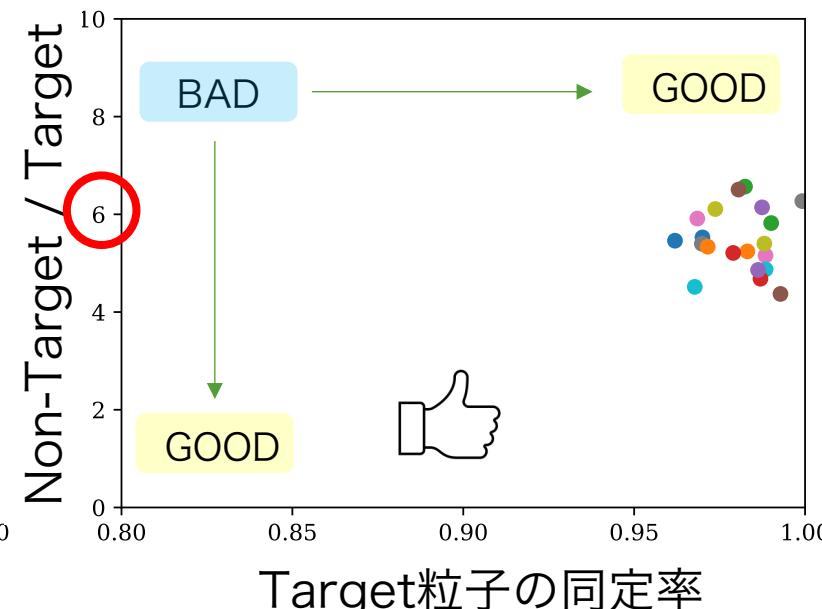
- Target粒子：超新星爆発の影響を受けた粒子 ($T > 100K$ かつ $dt < 1e5\text{ yr}$)
- Non-target粒子：選択した領域に存在するTarget粒子でない粒子
- 縦軸: Non-target 粒子の数 / 同定したtarget 粒子の数
- 横軸: Target粒子の同定率 (「同定した target 粒子の数 / 全 target 粒子の数」)。

解析解に基づく手法

$$(\text{Sedov解: } R(t) \propto \left(\frac{E_0}{\rho_0}\right)^{1/5} t^{2/5})$$



DLと画像処理を用いた手法



Enclosed region



Particle distribution



左: 予測された領域
右: Target粒子の分布

Summary

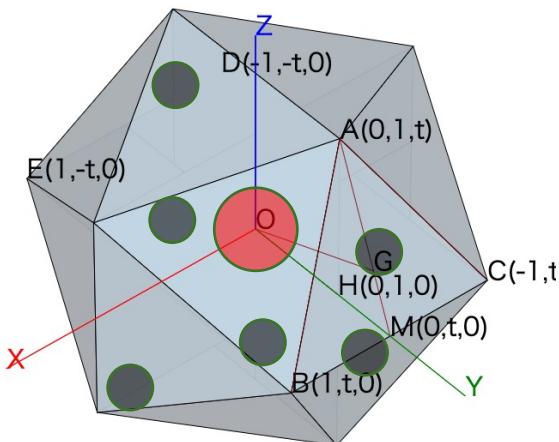
- ・今回開発した深層学習フレームワーク3D-MIMを用いて、超新星爆発による密度の時間・空間的変化を予測した。
- ・開発したアルゴリズムは、将来タイムステップが短くなる領域・粒子を十分な精度（解析解に基づく手法より良い性能）で同定可能になった。
- ・今後の課題
 - ・開発したアルゴリズムを我々の銀河形成シミュレーションに実装し、性能を確認する。
 - ・3D-MIMで他の物理量・現象も予測可能か調査する。
 - ・Mesh Simulationの予測に協力してくれる方を探しています！！

解析解に基づくシェル膨張の予測

- 解析解(Sedov解)に基づき、シェルが膨張する範囲を推定する。

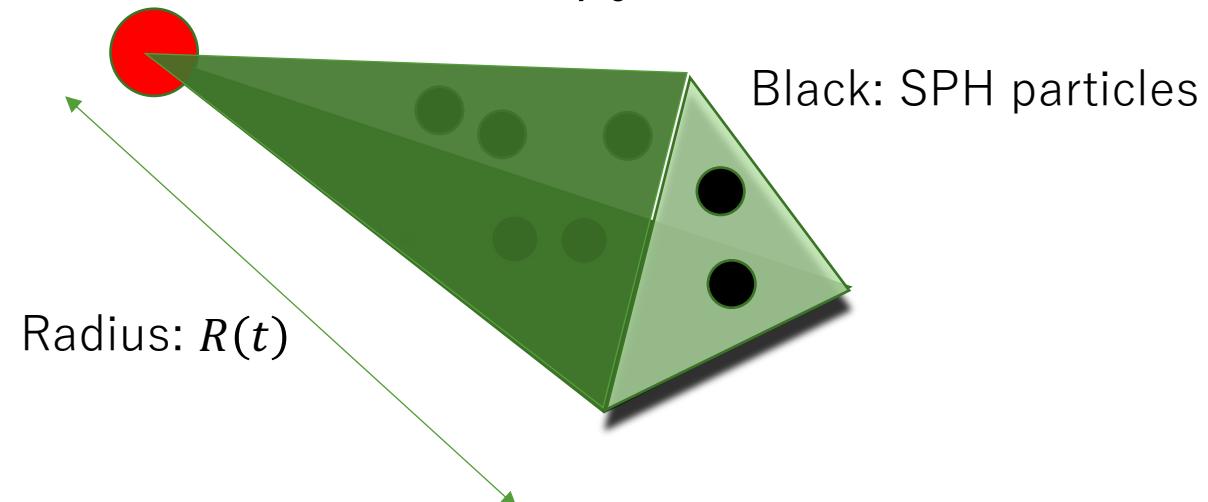
$$R(t) \propto \left(\frac{E_0}{\rho_0}\right)^{1/5} t^{2/5}$$

- 非等方性を考慮するために、爆発中心が中心となる正二十面体を用いて領域を20個に分割する。



Injected Energy: E_0

Density: ρ_0



<https://www.mathcal.org/canvas/20mentai-board/20mentai-board.html>